Статистическая проверка гипотез



Логистическая регрессия. Сигмоида. Функция ошибки в модели логистической регрессии. Кросс-валидация. Квантиль и квартиль. Дизайн эксперимента и статистические гипотезы о данных. Ошибки 1-го и 2-го рода. Статистическая значимость p-value. А/В тестирование. Тесты на нормальность. Корреляционные тесты. Проверка гипотезы t-критерия Стьюдента. Одновыборочный t-критерий. Двухвыборочный t-критерий для независимых выборок. Множественный тест (ANOVA).

Даниил Корбут

Специалист по Анализу Данных





Даниил КорбутDL Researcher
Insilico Medicine, Inc

Окончил бакалавриат ФИВТ МФТИ (Анализ данных) в 2018г Учусь на 2-м курсе магистратуры ФИВТ МФТИ Работал в Statsbot и Яндекс. Алиса.

Сейчас в Insilico Medicine, Inc, занимаюсь генерацией активных молекул и исследованиями старения с помощью DL.



Логистическая регрессия

Задача логистической регрессии - определить вероятность принадлежности к классу.

Построена на основе линейной функции.

$$h(x) = \theta^T x$$

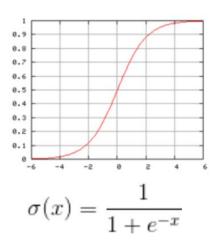
К линейной функции применяется функция активации:

$$h(x) = \sigma(\theta^T x)$$

Функция активации:

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$

Сигмоида



Производная сигмоиды:

$$\sigma'(x) = \sigma(x) \cdot (1 - \sigma(x))$$

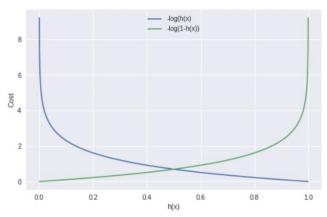


Функция ошибки логистической регрессии

Модель ищет параметры, которые минимизируют функцию ошибки:

$$cost = \begin{cases} -log(h(x)), & if \quad y = 1\\ -log(1 - h(x)), & if \quad y = 0 \end{cases}$$

Чем выше вероятность определения класса 1 при верном классе 0, тем выше стоимость ошибки.



Функция ошибки логистической регрессии

Общий вид функции ошибки для модели:

$$cost(h(x), y) = -y \cdot log(h(x)) - (1 - y)log(1 - h(x))$$

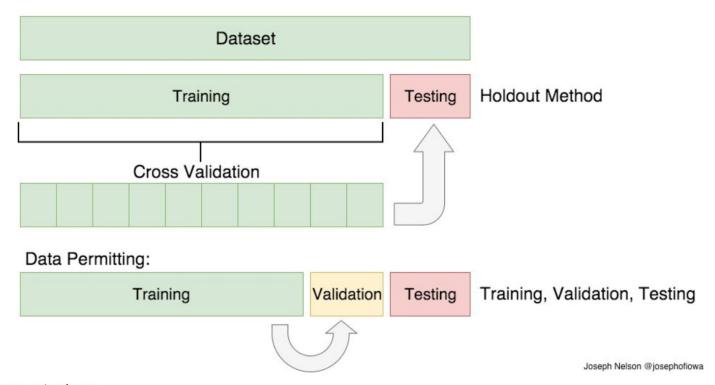
Ошибка для всех данных датасета:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^{m} \left[y^{i} log(h(x^{i})) + (1 - y^{i}) log(1 - h(x^{i})) \right]$$

Где т - количество элеметов.



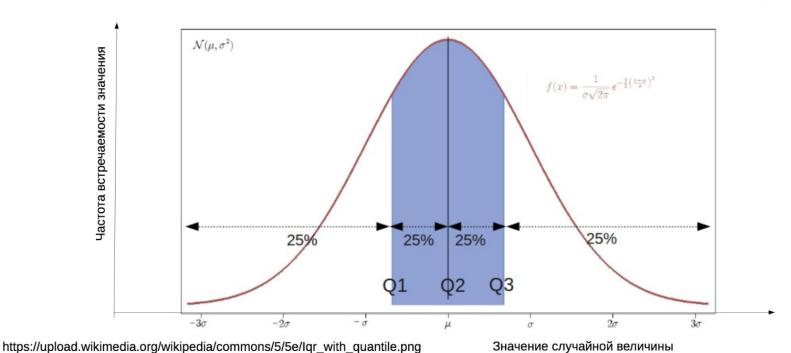
Кросс-валидация





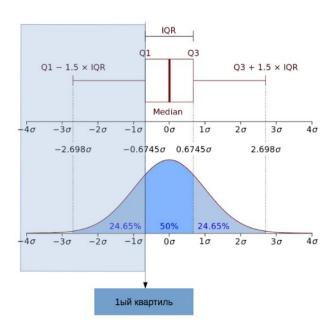
Квантиль

значение, которое заданная случайная величина не превышает с фиксированной вероятностью





Квартиль



Предоставляют важную информацию о структуре вариационного (колонку таблицы) ряда признака. Вместе с медианой они делят вариационный ряд на 4 равные части. Квартилей две, их обозначают символами Q, верхняя и нижняя квартиль. 25% значений меньше, чем нижняя квартиль, 75% значений меньше, чем верхняя квартиль.



Статистические гипотезы о данных

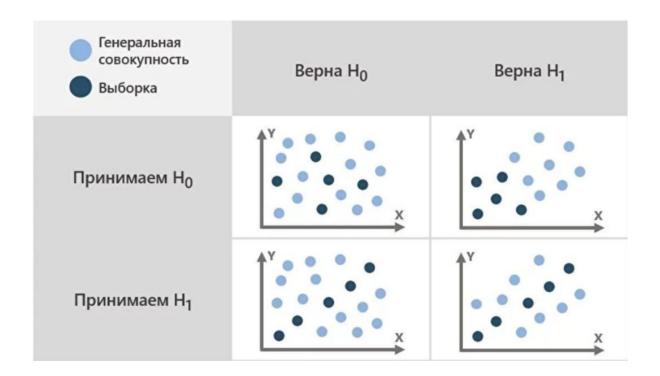
Выборочная совокупность — множество всех объектов, отобранных случайно из генеральной совокупности для изучения.



Нулевая гипотеза (Н0)— гипотеза о сходстве

Альтернативная гипотеза, конкурирующая, (Н1)— гипотеза о различиях

Нулевая и альтернативная гипотезы





Примеры основной и альтернативной гипотез

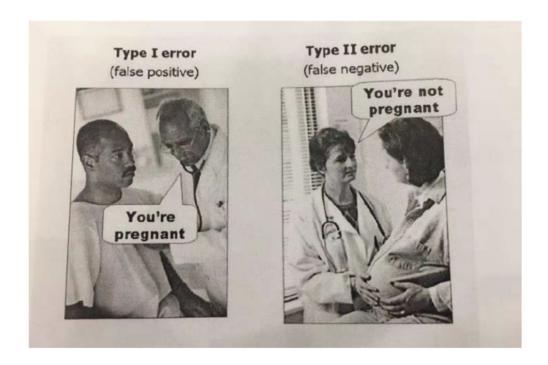
Основная гипотеза:

$$H_{_0}$$
 : $a = 368$ Средний вес выпускаемых коробок равен 368 г, конвейер работает нормально

Альтернативная гипотеза:

$$H_{_1}$$
 : $a \neq 368$ Средний вес выпускаемых коробок отличен от 368 г, конвейер требует наладки

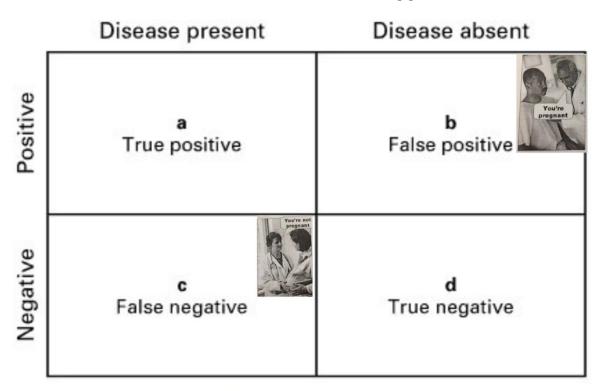
Пример: тест на беременность



https://blog.mathquant.com/2019/01/26/why-do-you-have-to-learn-to-lose-money-in-the-futures-market.html



Статистические гипотезы о данных



Ошибка 1 рода: Вероятность отвергнуть гипотезу, но в действительности она верна

Критически значимый уровень **alpha** = 0.05

Ошибка 2 рода:

Вероятность принять гипотезу, но в действительности она неверна **beta** — вероятность ошибки. Мощность исследования = 1-beta.

https://www.youtube.com/watch?v=4eyEp_NTXAU https://www.nejm.org/doi/full/10.1056/NEJM199908193410823



Статистическая значимость

СТАТИСТИЧЕСКАЯ ЗНАЧИМОСТЬ (ЗНАЧЕНИЕ Р)

— РАСЧЕТНАЯ ВЕРОЯТНОСТЬ ОШИБКИ ПЕРВОГО РОДА, КОТОРАЯ РАССЧИТЫВАЕТСЯ С ПОМОЩЬЮ РАЗЛИЧНЫХ СТАТИСТИЧЕСКИХ КРИТЕРИЕВ



P < 0.05



Виды статистических критериев

Критерии согласия -

исследуемая случайная величина подчиняется предполагаемому закону.

```
1 If Data Is Gaussian:
2 Use Parametric Statistical Methods
3 Else:
4 Use Nonparametric Statistical Methods
```

Параметрические критерии -

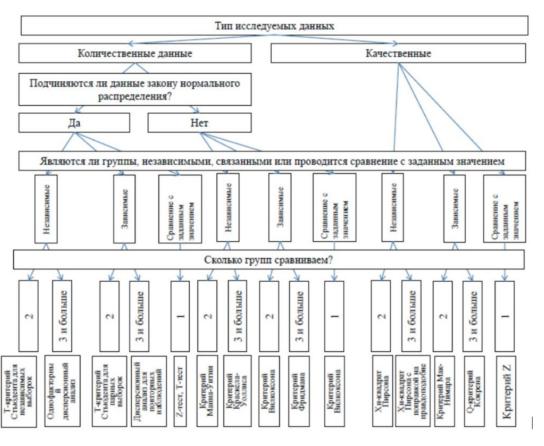
включают в расчет параметры вероятностного распределения признака (средние и дисперсии).

Непараметрические критерии -

которые не включают в расчёт параметры вероятностного распределения и основаны на оперировании частотами или рангами.



Схема применения критериев





Параметрические критерии

Параметрические критерии - группа статистических критериев, которые включают в расчет параметры вероятностного распределения признака (средние и дисперсии).

t-критерий Стьюдента Критерий Фишера Критерий отношения правдоподобия Критерий Романовского



t-критерий Стьюдента

Случайная величина t имеет распределение Стьюдента с n^{-1} степенями свободы, где n — размер выборки.

$$t = \frac{\bar{x} - \mu}{s / \sqrt{n}}$$

Критические значения t для заданного уровня доверия можно взять из таблицы:

https://www.kontrolnaya-rabota.ru/s/teoriya-veroyatnosti/tablica-studenta/



t-критерий Стьюдента

Если t-критерий HE превышает пороговое t, при p-lavel = 0.05 - 3 это значит, что у нас нет оснований для отклонения нулевой гипотезы.

Если фактическое **t** превышает критическое табличное значение при **p=0.05**, мы отклоняем нулевую гипотезу, — это означает, что мы обнаружили значимую закономерность!



Непараметрические критерии

Непараметрические критерии Группа статистических критериев, которые не включают в расчёт параметры вероятностного распределения и основаны на оперировании частотами или рангами.

О-критерий Розенбаума
U-критерий Манна — Уитни
Критерий Уилкоксона
Критерий Пирсона
Критерий Колмогорова — Смирнова



А/В тесты

А/В тестирование — это мощный маркетинговый инструмент для повышения эффективности работы вашего интернет-ресурса.

Ниже на картинках приведены примеры распределения значений показателя в

сегментах.



Пример А/В теста

Компания WallMonkeys решила оптимизировать веб-сайт на клики и конверсию.







Пример А/В теста

1 тест: 27% кликов.

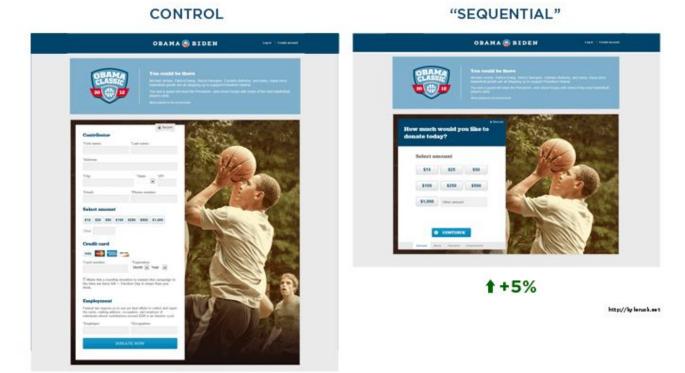


2 тест: 550% кликов





Пример А/В теста





Спасибо за внимание!

